

**模式识别与机器学习**

**Pattern Recognition  
and Machine Learning**

# 课程内容

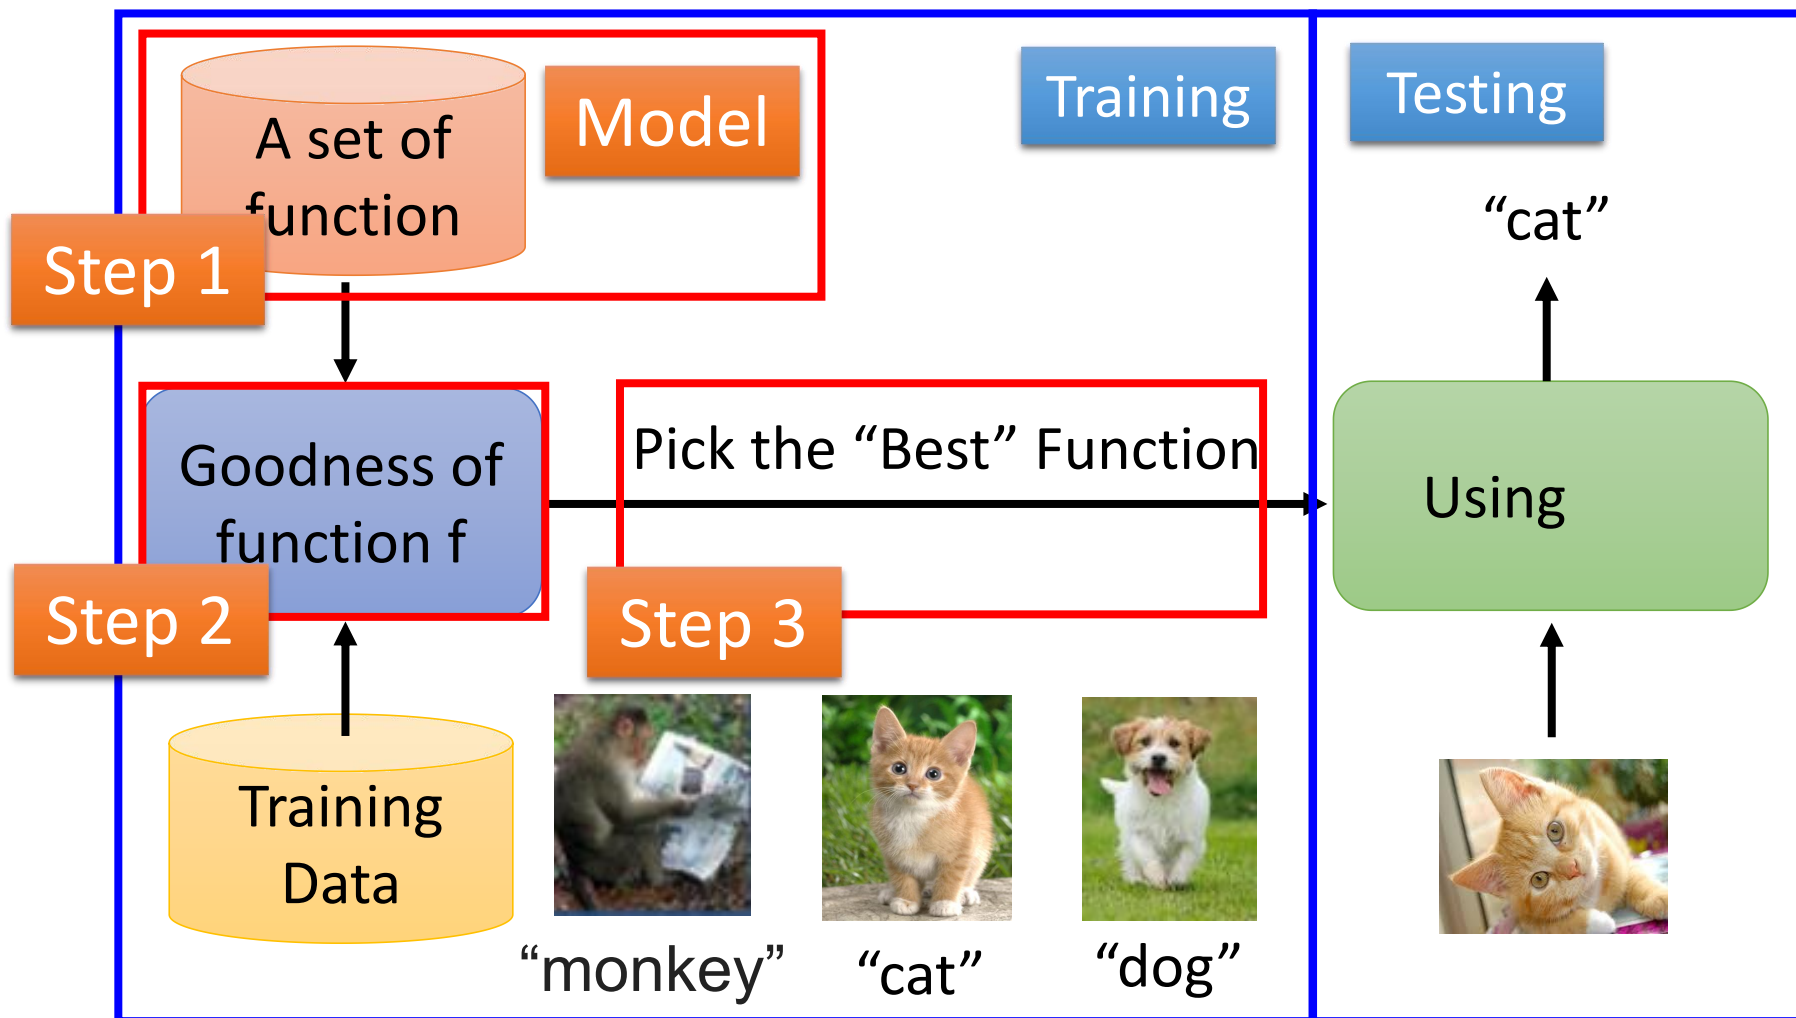
## ■ 模式识别与机器学习概述

## ■ 模式识别与机器学习的基本方法

- 回归分析、线性判别函数、线性神经网络、核方法和支持向量机、决策树分类
- 贝叶斯统计决策理论、概率密度函数估计
- 无监督学习和聚类
- 特征选择与提取

# 监督式学习--三段式解法

## ■ 有监督学习： 找一个函数的能力



# 监督式学习--三段式解法

## ■ 有监督学习： 找一个函数的能力

Step 0: What kind of function do you want to find?

Regression, Classification, .....

Step 1:  
define a set  
of function

Linear Classifier  
Probabilistic  
SVM  
Deep Learning  
Decision Tree



Step 2:  
goodness of  
function

Regression(MSE)  
Classification (Cross  
Entropy)  
.....



Step 3: pick  
the best  
function

Gradient Descent  
.....

# 回归分析任务简述

- 监督学习从给定的训练数据集中学习出数据及其标记的映射函数，当新的数据到来时，可以根据这个函数预测新数据的结果。训练集中的数据标记是由人标注的。
- 常见的监督学习算法包括回归分析和分类。
  - 回归：函数的输出是一个连续的值
  - 分类：函数的输出是一个离散的值（二分类、多分类）

# 监督式学习--三段式解法

## ■ Step 1: Model (模型)

$$y = b + w \cdot x$$

A set of  
function

Model

$f_1, f_2 \dots$

w and b are parameters  
(can be any value)

$$f_1: y = 10.0 + 9.0 \cdot x$$

$$f_2: y = 9.8 + 9.2 \cdot x$$

$$f_3: y = -0.8 - 1.2 \cdot x$$

..... infinite

$$f(x) = y$$

Linear model:

$$y = b + \sum w_i x_i$$

$x_i: x_{cp}, x_{hp}, x_w, x_h \dots$

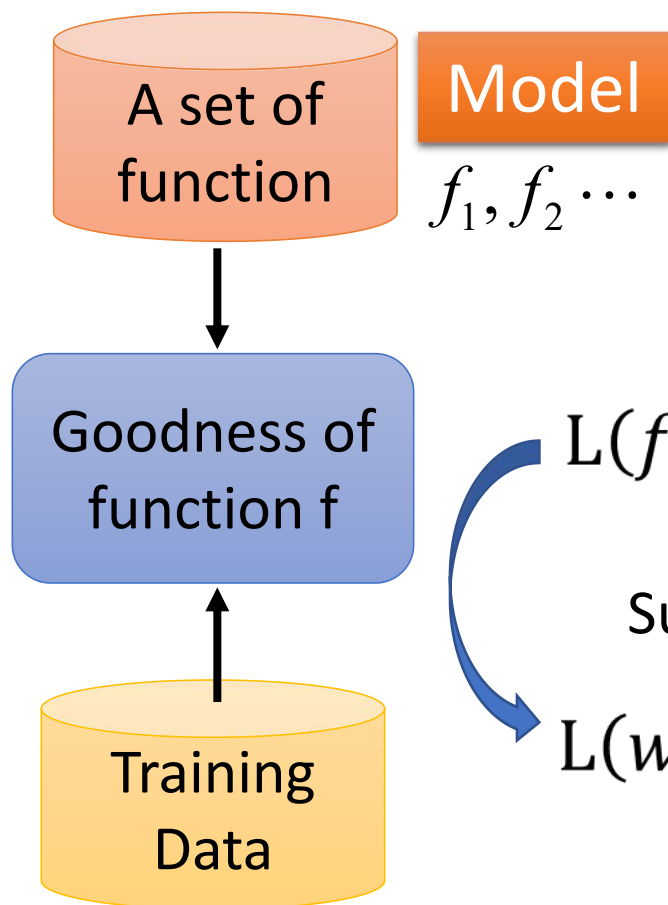
feature

$w_i$ : weight, b: bias

# 监督式学习--三段式解法

## ■ Step 2: Goodness of Function (策略)

$$y = b + w \cdot x$$



Loss function  $L$ :

Input: a function, output:  
how bad it is

$$L(f) = \sum_{n=1}^{10} \boxed{\hat{y}^n - \underline{f(x^n)}}^2$$

Sum over examples

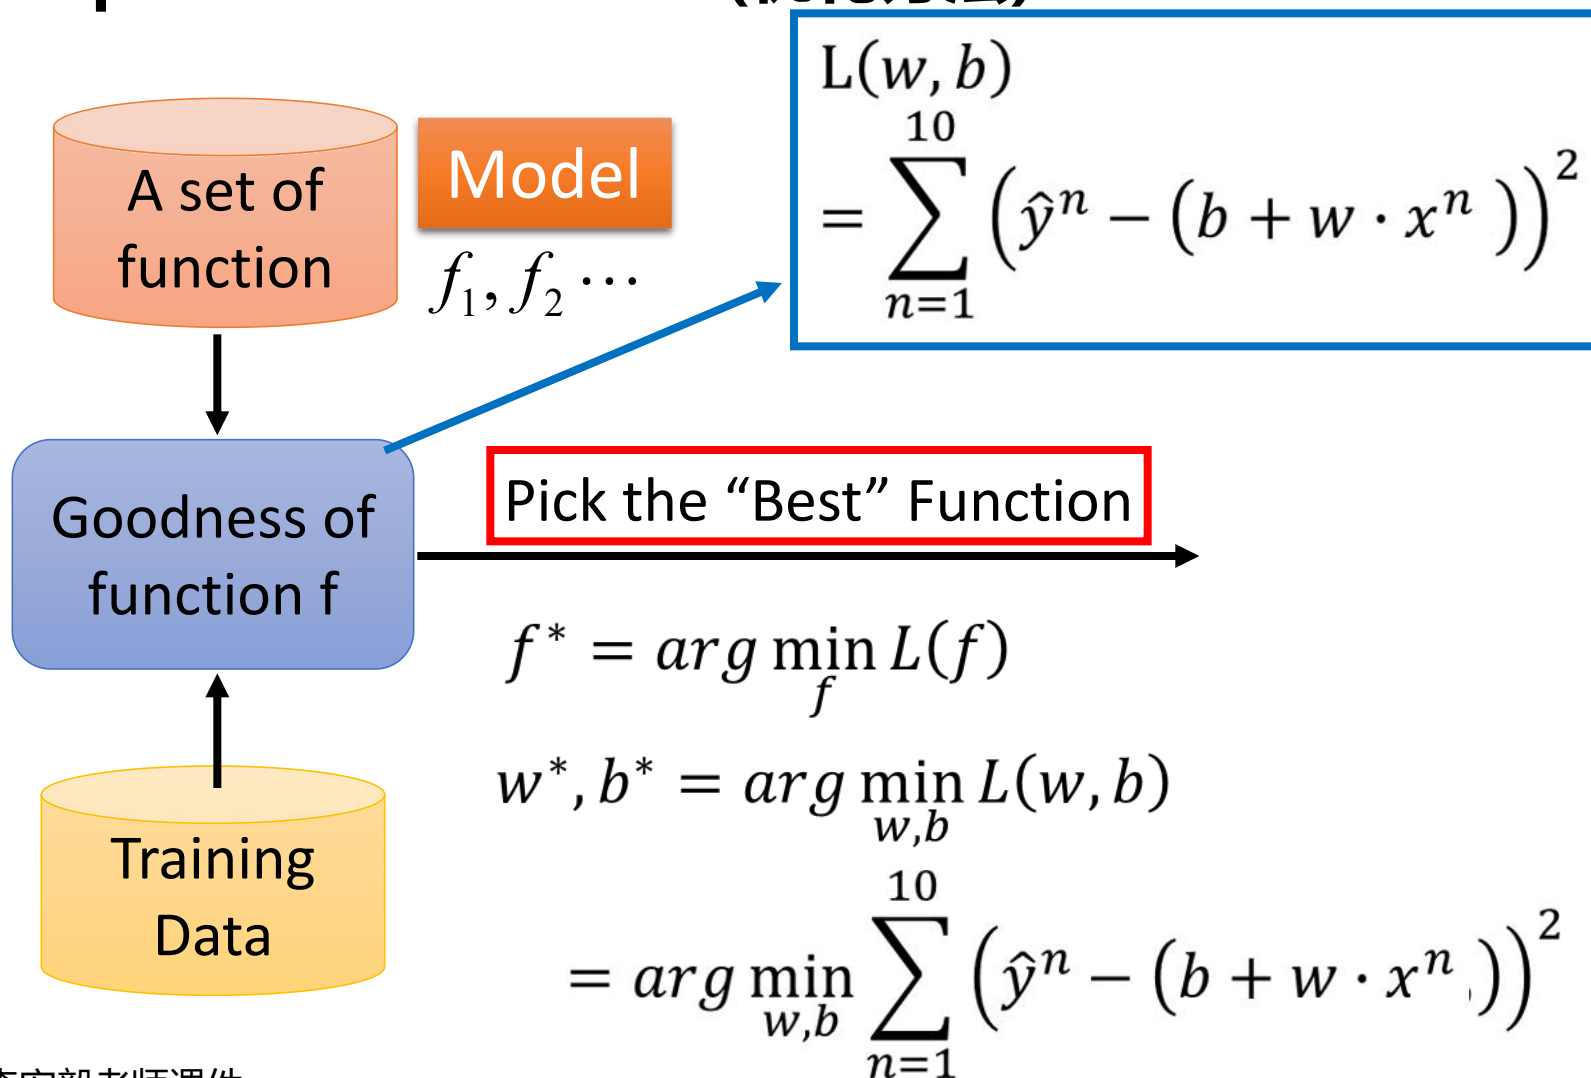
Estimation error

Estimated  $y$  based on input function

$$L(w, b) = \sum_{n=1}^{10} \left( \hat{y}^n - (b + w \cdot x^n) \right)^2$$

# 监督式学习--三段式解法

## ■ Step 3: Best Function (优化方法)





# 课程内容

## ■ 回归分析

- 回归分析任务简述
- 多元线性回归
- 多项式回归
- 其他回归方法

# 多元线性回归

## ■ 线性模型一般形式

$$f(\mathbf{x}) = w_1x_1 + w_2x_2 + \dots + w_dx_d + b$$

是由属性  $\mathbf{x} = (x_1; x_2; \dots; x_d)$  的示例, 其中  $x_i$  是  $\mathbf{x}$  在第  $i$  个属性上的取值

## ■ 向量形式

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中  $\mathbf{w} = (w_1; w_2; \dots; w_d)$

# 多元线性回归

- 形式简单、易于建模
- 可解释性
- 非线性模型的基础
  - 引入层级结构或高维映射
- 一个例子
  - 综合考虑色泽、根蒂和敲声来判断西瓜好不好
  - 其中根蒂的系数最大，表明根蒂最要紧；而敲声的系数比色泽大，说明敲声比色泽更重要

$$f_{\text{好瓜}}(\mathbf{x}) = 0.2 \cdot x_{\text{色泽}} + 0.5 \cdot x_{\text{根蒂}} + 0.3 \cdot x_{\text{敲声}} + 1$$

# 多元线性回归

■ 给定数据集  $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$

其中  $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id})$   $y_i \in \mathbb{R}$

■ 线性回归 (linear regression) 目的

学得一个线性模型以尽可能准确地预测实值输出标记

■ 模型 (Model of Step 1) 确定后, 如何确定具体的线性模型



# 多元线性回归

## ■ 单一属性的线性回归目标

$$f(x) = wx_i + b \quad \text{使得} \quad f(x_i) \simeq y_i$$

## ■ 参数/模型估计：最小二乘法 (least square method)

$$\begin{aligned}(w^*, b^*) &= \arg \min_{(w, b)} \sum_{i=1}^m (f(x_i) - y_i)^2 \\ &= \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2\end{aligned}$$

# 多元线性回归

## ■ 最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$$

## ■ 分别对 $w$ 和 $b$ 求导, 可得

$$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right)$$

# 多元线性回归

- 得到闭式 (closed-form) 解

$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

- 其中

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

# 多元线性回归

## ■ 给定数据集

$$D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$$

$$\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{id}) \quad y_i \in \mathbb{R}$$

## ■ 多元线性回归目标

$$f(\mathbf{x}_i) = \mathbf{w}^T \mathbf{x}_i + b \quad \text{使得} \quad f(\mathbf{x}_i) \simeq y_i$$



# 多元线性回归

- 把 $w$ 和 $b$ 吸收入向量形式  $\hat{w} = (w; b)$  数据集表示为

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1d} & 1 \\ x_{21} & x_{22} & \cdots & x_{2d} & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{m1} & x_{m2} & \cdots & x_{md} & 1 \end{pmatrix} = \begin{pmatrix} \mathbf{x}_1^T & 1 \\ \mathbf{x}_2^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{pmatrix}$$

$$\mathbf{y} = (y_1; y_2; \cdots; y_m)$$

# 多元线性回归

## ■ 最小二乘法 (least square method)

$$\hat{\boldsymbol{w}}^* = \arg \min_{\hat{\boldsymbol{w}}} (\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}}^T) (\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}})$$

令  $E_{\hat{\boldsymbol{w}}} = (\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}})^T (\boldsymbol{y} - \mathbf{X}\hat{\boldsymbol{w}})$  , 对 $\hat{\boldsymbol{w}}$ 求导得到

$$\frac{\partial E_{\hat{\boldsymbol{w}}}}{\partial \hat{\boldsymbol{w}}} = 2\mathbf{X}^T (\mathbf{X}\hat{\boldsymbol{w}} - \boldsymbol{y})$$

令上式为零可得 $\hat{\boldsymbol{w}}$ 最优解的闭式解

# 多元线性回归

- $\mathbf{X}^T \mathbf{X}$  是满秩矩阵或正定矩阵, 则

$$\hat{\mathbf{w}}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

其中 $(\mathbf{X}^T \mathbf{X})^{-1}$ 是 $\mathbf{X}^T \mathbf{X}$  的逆矩阵, 线性回归模型为

$$f(\hat{\mathbf{x}}_i) = \hat{\mathbf{x}}_i^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

- $\mathbf{X}^T \mathbf{X}$  不是满秩矩阵
  - 引入正则化

# 多元线性回归--解析法回顾

- 对一元线性回归，最小化均方误差

$$E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$$

- 分别对 $w$  和  $b$  求导，可得

$$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right)$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right)$$

# 多元线性回归--解析法回顾

- 得到闭式 (closed-form) 解

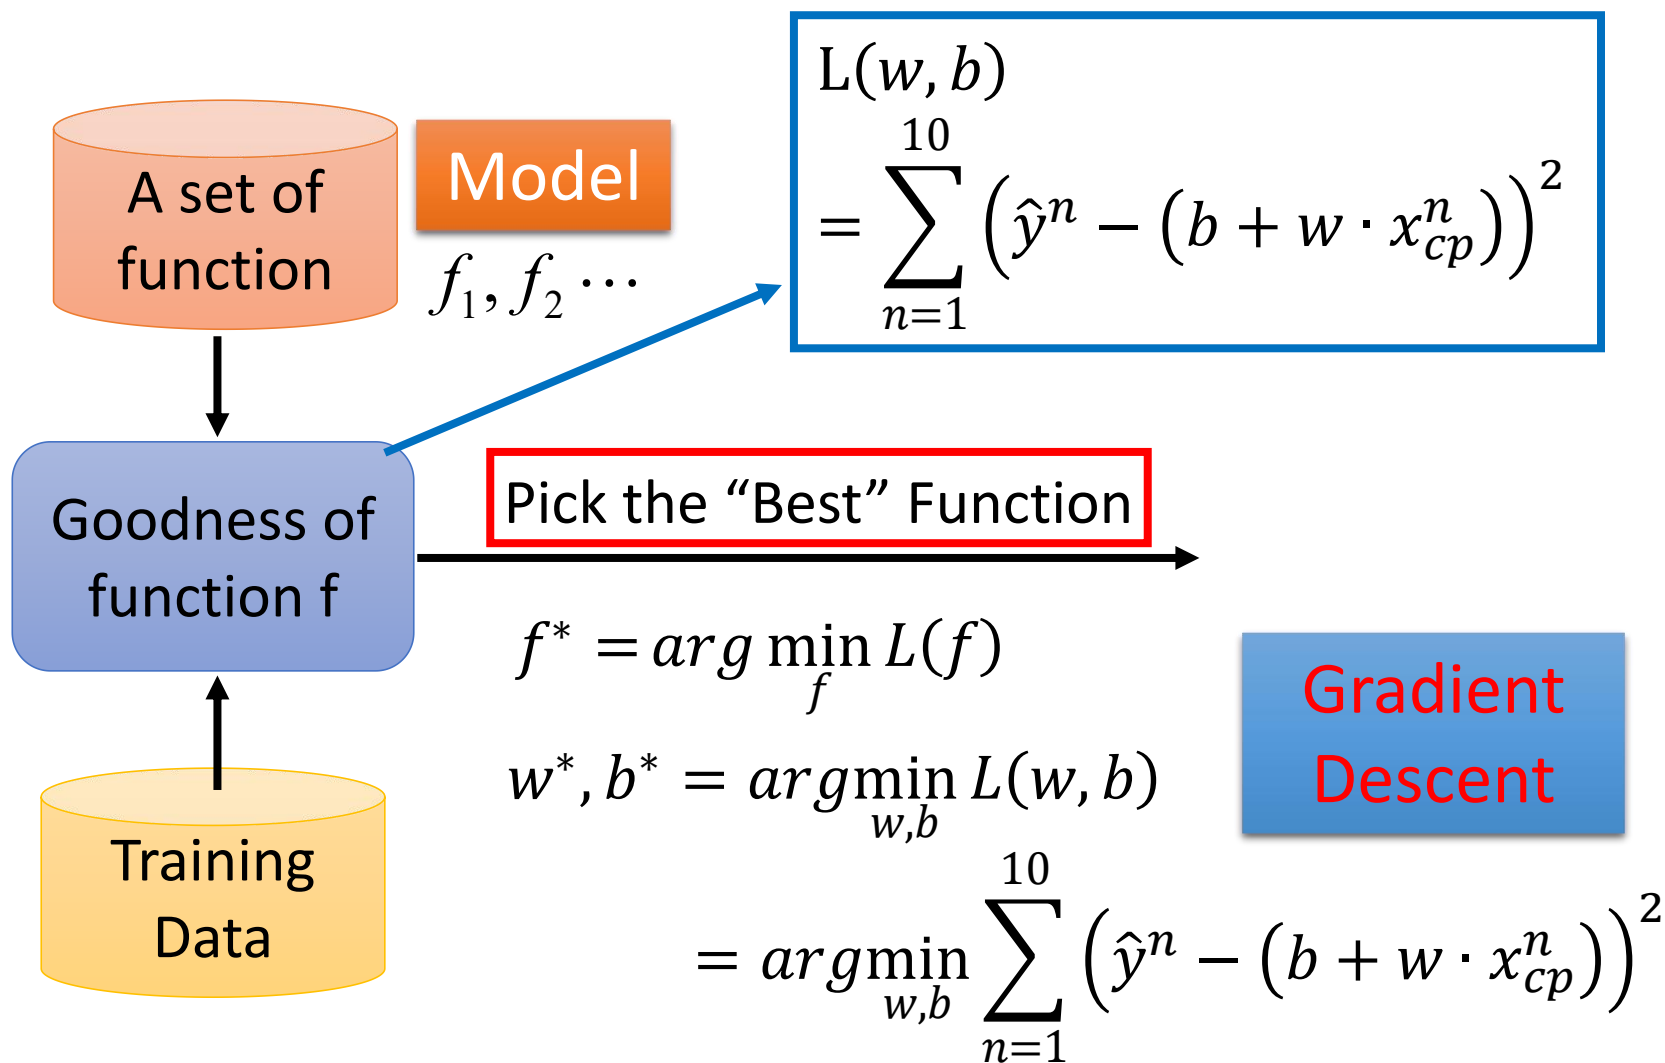
$$w = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2}$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i)$$

- 其中

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

# 多元线性回归--梯度下降法



# 多元线性回归--梯度下降法

## ■ Step 3: Best Function

$$\nabla L = \begin{bmatrix} \frac{\partial L}{\partial w} \\ \frac{\partial L}{\partial b} \end{bmatrix} \text{gradient}$$

- How about two parameters?  $w^*, b^* = \arg \min_{w, b} L(w, b)$

➤ (Randomly) Pick an initial value  $w^0, b^0$

➤ Compute  $\frac{\partial L}{\partial w} |_{w=w^0, b=b^0}, \frac{\partial L}{\partial b} |_{w=w^0, b=b^0}$

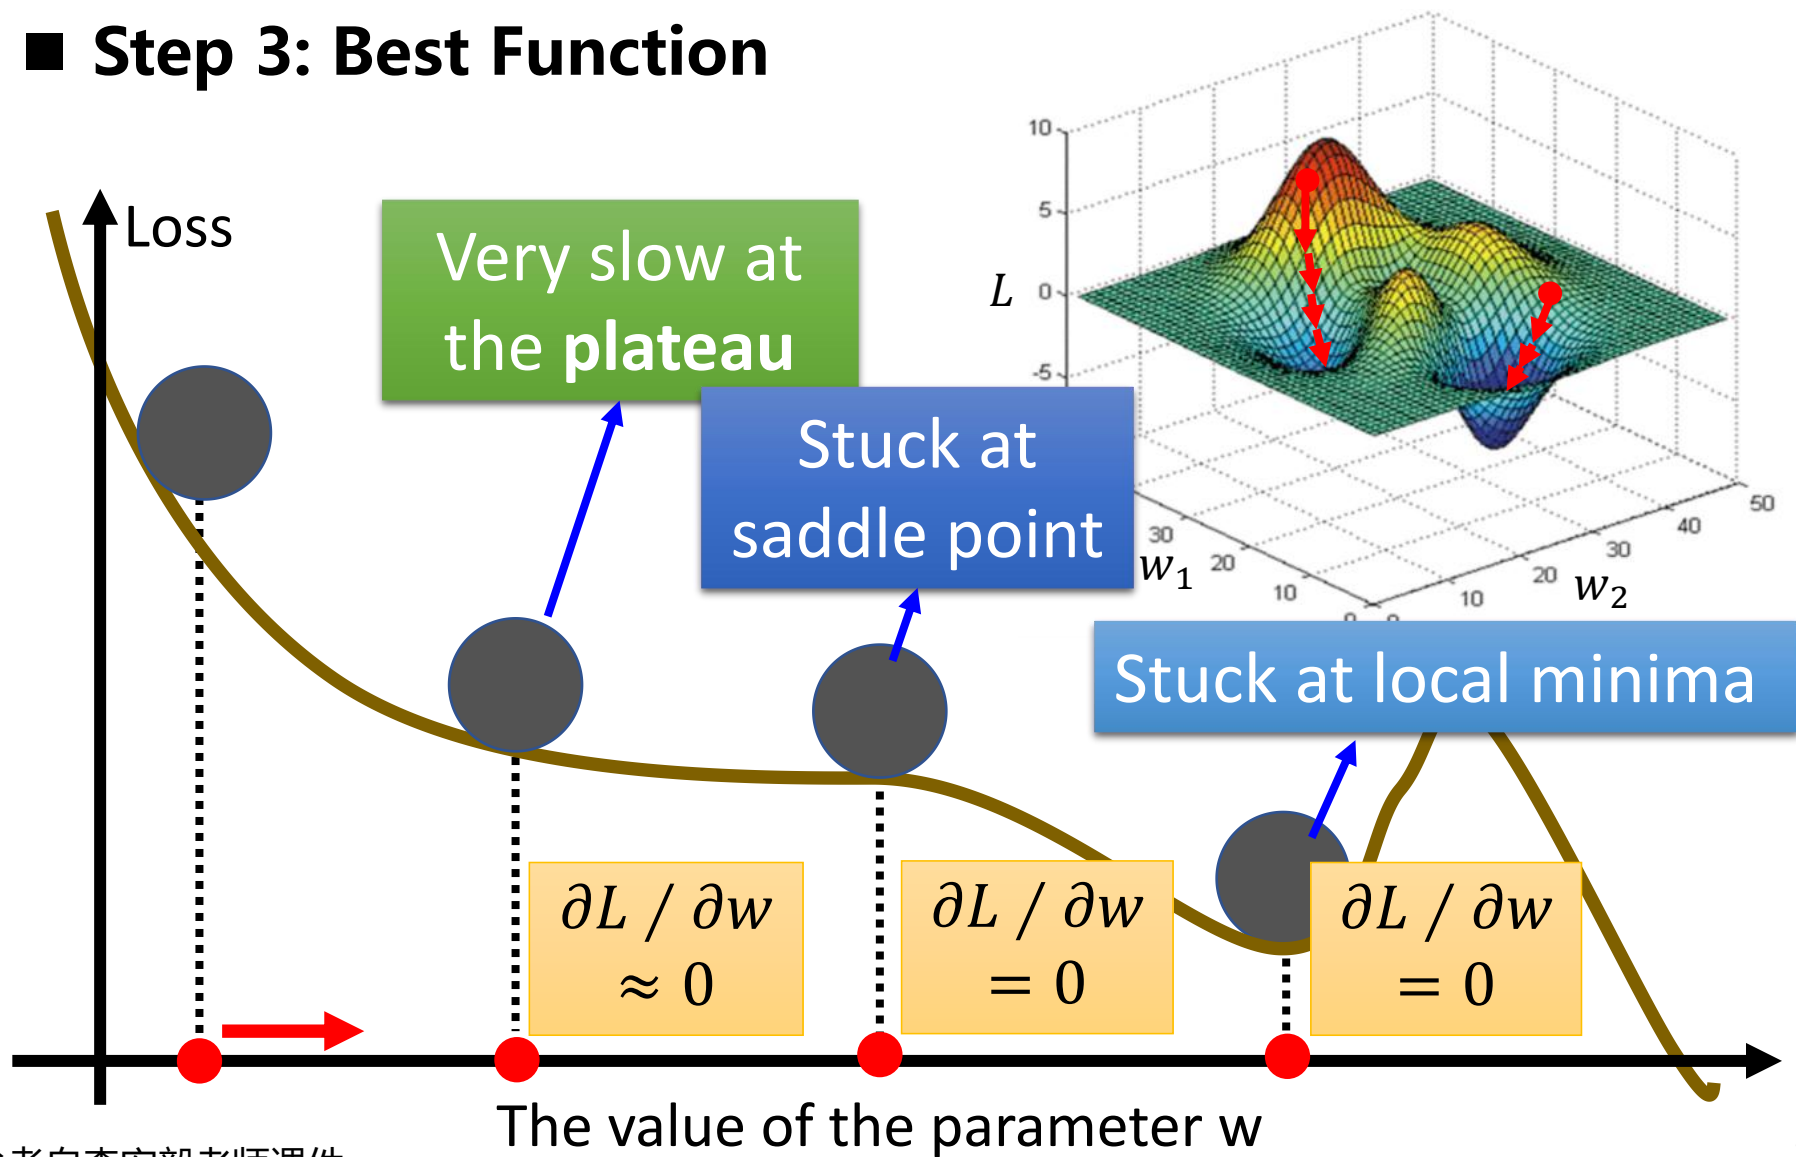
$$w^1 \leftarrow w^0 - \eta \frac{\partial L}{\partial w} |_{w=w^0, b=b^0} \quad b^1 \leftarrow b^0 - \eta \frac{\partial L}{\partial b} |_{w=w^0, b=b^0}$$

➤ Compute  $\frac{\partial L}{\partial w} |_{w=w^1, b=b^1}, \frac{\partial L}{\partial b} |_{w=w^1, b=b^1}$

$$w^2 \leftarrow w^1 - \eta \frac{\partial L}{\partial w} |_{w=w^1, b=b^1} \quad b^2 \leftarrow b^1 - \eta \frac{\partial L}{\partial b} |_{w=w^1, b=b^1}$$

# 多元线性回归--梯度下降法

## ■ Step 3: Best Function





# 多项式回归

## ■ 线性函数?


$$y = b + w \cdot x$$

$$b = -188.4$$

$$w = 2.7$$

Average Error on  
Training Data

$$= \frac{1}{10} \sum_{n=1}^{10} e^n = 31.9$$



# 多项式回归

## ■ 线性函数?

$$y = b + w \cdot x$$

$$b = -188.4$$

$$w = 2.7$$


Average Error on  
Testing Data

$$= \frac{1}{10} \sum_{n=1}^{10} e^n = 35.0$$

> Average Error on  
Training Data (31.9)

What we really care about is the error on new data (testing data)

Another 10 data as testing data



# 多项式回归

## ■ 线性函数？二次多项式函数

$$y = b + w_1 \cdot x + w_2 \cdot (x)^2$$

### Best Function

$$b = -10.3$$



$$w_1 = 1.0, w_2 = 2.7 \times 10^{-3}$$

$$\text{Average Error} = 15.4$$

### Testing:

$$\text{Average Error} = 18.4$$

Better! Could it be even better?



# 多项式回归

## ■ 线性函数？三次多项式函数

$$y = b + w_1 \cdot x + w_2 \cdot (x)^2 + w_3 \cdot (x)^3$$

### Best Function

$$b = 6.4, w_1 = 0.66$$

$$w_2 = 4.3 \times 10^{-3}$$

$$w_3 = -1.8 \times 10^{-6}$$



$$\text{Average Error} = 15.3$$

### Testing:

$$\text{Average Error} = 18.1$$

Slightly better.

How about more complex model?



# 多项式回归

## ■ 线性函数？四次多项式函数

$$y = b + w_1 \cdot x + w_2 \cdot (x)^2 + w_3 \cdot (x)^3 + w_4 \cdot (x)^4$$



### Best Function

Average Error = 14.9

### Testing:

Average Error = 28.8

The results become worse ...



# 多项式回归

## ■ 线性函数？五次多项式函数

$$y = b + w_1 \cdot x + w_2 \cdot (x)^2 + w_3 \cdot (x)^3 + w_4 \cdot (x)^4 + w_5 \cdot (x)^5$$



### Best Function

Average Error = 12.8

### Testing:

Average Error = 232.1

The results are so bad.



# 多项式回归

## ■ 模型选择

1.  $y = b + w \cdot x_{cp}$



2.  $y = b + w_1 \cdot x_{cp} + w_2 \cdot (x_{cp})^2$

3.  $y = b + w_1 \cdot x_{cp} + w_2 \cdot (x_{cp})^2 + w_3 \cdot (x_{cp})^3$

4.  $y = b + w_1 \cdot x_{cp} + w_2 \cdot (x_{cp})^2 + w_3 \cdot (x_{cp})^3 + w_4 \cdot (x_{cp})^4$

5.  $y = b + w_1 \cdot x_{cp} + w_2 \cdot (x_{cp})^2 + w_3 \cdot (x_{cp})^3 + w_4 \cdot (x_{cp})^4 + w_5 \cdot (x_{cp})^5$

Training Data




A more complex model yields lower error on training data.

If we can truly find the best function

# 多项式回归

## ■ 模型选择



	Training	Testing
1	31.9	35.0
2	15.4	18.4
3	15.3	18.1
4	14.9	28.2
5	12.8	232.1


A more complex model does not always lead to better performance on testing data.

This is Overfitting.  Select suitable model



# 多项式回归





## ■ 实验练习（鼓励）



$$\mathbf{f}(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_jx^j$$


# 多项式回归

## ■ 实验练习 (鼓励)



# 多项式回归

## ■ 实验练习（鼓励）



	M = 0	M = 1	M = 3	M = 9
w <sub>0</sub>	0.19	0.82	0.31	0.35
w <sub>1</sub>		-1.27	7.99	232.37
w <sub>2</sub>			-25.43	-5321.83
w <sub>3</sub>			17.37	48568.31
w <sub>4</sub>				-231639.30
w <sub>5</sub>				640042.26
w <sub>6</sub>				-1061800.52
w <sub>7</sub>				1042400.18
w <sub>8</sub>				-557682.99
w <sub>9</sub>				125201.43

如何确定适当的 $M$ （多项式阶数）？如何防止过拟合？

# 多项式回归

## ■ 多项式回归--正则化

损失函数

$$E(w) = \frac{1}{2} \sum_{n=0}^{N-1} \{y_n - \mathbf{f}(x_n, w)\}^2$$

具有更小的 $w$ 更好

带有正则化的回归

$$E(w) = \frac{1}{2} \sum_{n=0}^{N-1} (y_n - \mathbf{f}(x_n, w))^2 + \boxed{\frac{\lambda}{2} \|w\|^2}$$

➤ 更小的  $w$  意味着... smoother

$$y = b + \sum w_i x_i$$

$$y + \sum w_i \Delta x_i = b + \sum w_i (x_i + \Delta x_i)$$

➤ 我们认为越平滑的函数效果越好。

# 多项式回归


## ■ 多项式回归--正则化

$$E(w) = \frac{1}{2} \sum_{n=0}^{N-1} (y_n - \mathbf{f}(x_n, w))^2 + \frac{\lambda}{2} \|w\|^2$$

- 当 $w$  非常小(趋近于0)时, 输入变化对结果的影响趋近于0。
- 我们可以通过调整 $\lambda$ 参数来调整正则化的强度。
- $\lambda$ 越大, 模型曲线越平滑。
- 我们不需要对 $b$ 进行正则化, 因为 $b$ 只影响模型曲线的上下移动( $b$ 是常数), 所以我们不需要对其进行调整。

# 多项式回归


## ■ 偏差 VS 方差



# 多项式回归

## ■ 怎样处理大的偏差（欠拟合）

- Diagnosis:
  - If your model cannot even fit the training examples, then you have large bias **Underfitting**
  - If you can fit the training data, but large error on testing data, then you probably have large variance **Overfitting**
- For bias, redesign your model:
  - Add more features as input
  - A more complex model

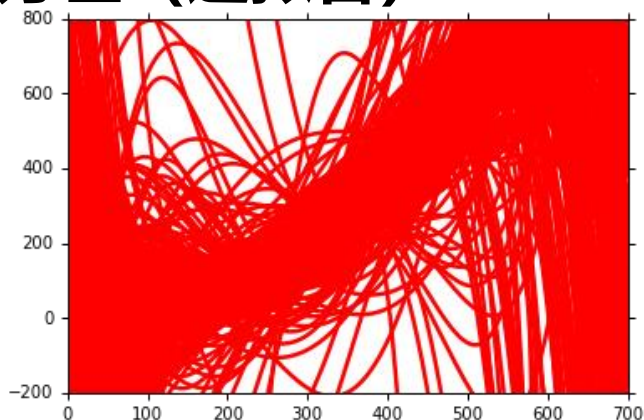


# 多项式回归


## ■ 怎样处理大的方差（过拟合）

- More data

Very effective,  
but not always  
practical




10 examples





100 examples

- Regularization



May increase bias






# 其他回归方法

## ■ 对数线性模型

输出标记的对数为线性模型逼近的目标



$$\ln y = w^T x + b$$



$$y = w^T x + b$$

# 其他回归方法

## ■ 广义线性模型

### ➤ 一般形式

$$y = g^{-1}(\mathbf{w}^T \mathbf{x} + b)$$

### ➤ $g(\cdot)$ 称为联系函数 (link function)

#### ➤ 单调可微函数

### ➤ 对数线性回归是 $g(\cdot) = \ln(\cdot)$ 时广义线性模型的特例

# Thanks

---